kaggle系列（2）：Rental Listing Inquiries（一）：EDA

2017-06-13 | Kaggle | 45

一、比赛简介

1.1 比赛目的

这个kaggle比赛是由Sigma和RentHop两家公司共同推出的比赛。比赛的数据来自于RentHop的租房信息，大概的思路就是根据出租房的一系列特征，比如地理位置（经纬度、街道地址）、发布时间、房间设施（浴室、卧室数量）、描述信息、发布的图片信息、价格等来预测消费者对出租房的喜好程度。

这样可以帮助RentHop公司更好地处理欺诈事件，让房主和中介更加理解租客的需求与偏好，做出更加合理的决策。

1.2 数据集

在这个比赛中，房源的数据来自于renthop网站，这些公寓都位于纽约市。其目的之前已经提到过了，就是基于一系列特征预测公寓房源的受欢迎程度，其目标变量是： `interest_level` ，它是指从在网站上发布房源起始的时间内，房源的询问次数。

其中，比赛一共给了五个数据文件，分别是：

- train.json：训练集
- test.json：测试集
- sample_submission.csv：格式正确的提交示例
- images_sample.zip：租房图片集（只抽取了100个图片集）
- kaggle-renthop.7z：所有的租房图片集，一共有78.5GB的压缩文件。

给出的特征的含义：

- bathrooms: 浴室的数量
- bedrooms: 卧室的数量
- building_id：
- created：发布时间
- description：一些描述
- display_address：展出地址
- features: 公寓的一些特征
- latitude：纬度
- listing_id
- longitude：经度
- manager_id：管理ID
- photos: 租房图片集
- price: 美元
- street_address：街道地址
- interest_level: 目标变量，受欢迎程度. 有三个类: 'high', 'medium', 'low'

1.3 提交要求

这个比赛使用的是多分类对数似然损失函数来评价模型。因为每一个房源都有一个对应的最准确的类别，对每一个房源，需要提交它属于每一类的概率值，它的计算公式如下：

$$\log loss = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{M} y_{ij}\log(p_{ij})$$

其中N是测试集中的样本数量，M是类别的数量（3类：high、medium、low）,log是自然对数，y_{ij}表示样本i属于j类则为1，否则为0.p_{ij}表示样本i属于类别j的预测概率值。

一个样本的属于三个类别的预测可能性不需要加和为1，因为已经预先归一化了。为避免对数函数的极端情况，预测概率被替代为$max(min(p, 1-10^{-15}), 10^{-15})$

最后提交的文件为csv格式，它包含对每一类的预测概率值，行的顺序没有要求，文件必须要有一个表头，看起来像下面的示例：

listing_id	high	medium	low
7065104	0.07743	0.23002	0.69254

listing_id	high	medium	low
7089035	0.0	1.0	0.0

二、Exploratory Data Analysis

在进行建模之前，我们都会对原始数据进行一些可视化探索，以便更快地熟悉数据，更有效进行之后的特征工程和建模。

我们先导入一些EDA过程中所需要的包：

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import json
color = sns.color_palette() # 调色板

%matplotlib inline

pd.options.mode.chained_assignment = None # default = 'warn'
```

其中numpy和pandas是数据分析处理中最流行的包，matplotlib和seaborn两个包用来绘制可视化图像，使用%matplotlib命令可以将matplotlib的图表直接嵌入到Notebook之中（%是魔术命令）。

2.1 数据初探

使用pandas打开训练集文件train.json，取前两行观测：

```
train_df = pd.read_json('data/train.json')
train_df.head(8)
```

	bathrooms	bedrooms	building_id	created	description	display_address	features	interest_level
10	1.5	3	53a5b119ba8f7b61d4e010512e0dfc85	2016-06-24 07:54:24	A Brand New 3 Bedroom 1.5 bath ApartmentEnjoy ...	Metropolitan Avenue	[]	medium
10000	1.0	2	c5c8a357cba207596b04d1afd1e4f130	2016-06-12 12:19:27		Columbus Avenue	[Doorman, Elevator, Fitness Center, Cats Allow...	low

latitude	listing_id	longitude	manager_id	photos	price	street_address
40.7145	7211212	-73.9425	5ba989232d0489da1b5f2c45f6688adc	[https://photos.renthop.com/2/7211212_1ed4542e...	3000	792 Metropolitan Avenue
40.7947	7150865	-73.9667	7533621a882f71e25173b27e3139d83d	[https://photos.renthop.com/2/7150865_be3306c5...	5465	808 Columbus Avenue

我们可以看到给定的数据中包含各种类型的特征，按照其特征可以分为以下几个类别：

特征类型	特征
数值型	bathrooms、bedrooms、price
高势集类别	building_id、display_address、manager_id、street_address
时间型	created
地理位置型特征	longitude、latitude
文本	description
稀疏特征	features
id型特征	listing_id、index

看一下训练集和测试集分别有多少

```
1   print "Train Rows:",train_df.shape[0]
2   print "Test Rows:",test_df.shape[0]
```

Train Rows: 49352

Test Rows: 74659

训练集有49352个样例，测试集有74659个样例。

接下来我们一一对这些特征进行探索。

2.2 目标变量

在深入探索之前，我们先看看目标变量Interest level

```
int_level = train_df['interest_level'].value_counts()
plt.figure(figsize=(10,5))
sns.barplot(int_level.index,int_level.values,alpha=0.8,color=color[2])
plt.xlabel("number of occurrences",fontsize = 12)
plt.ylabel("Interest Level",fontsize=12)
plt.show()
```

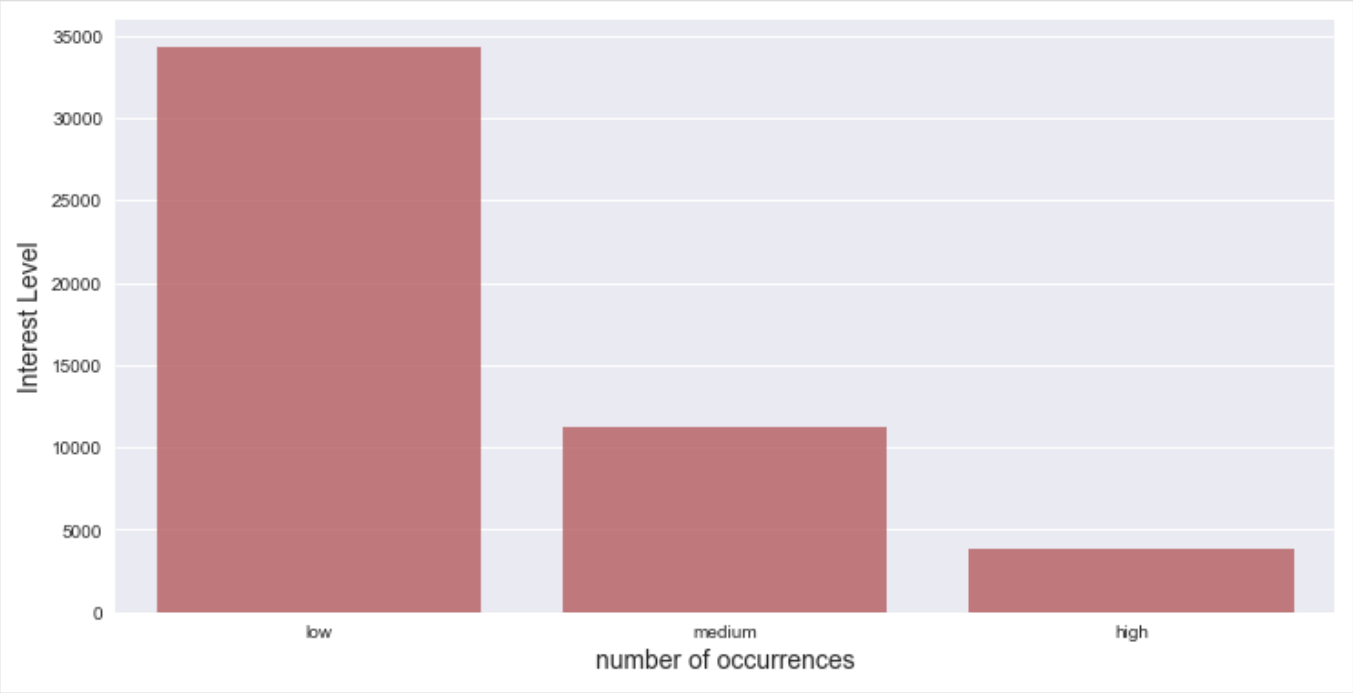

兴趣度在大多数情况下都是低的，其次是中等，只有少部分的样例为高分。

2.3 数值型特征

2.3.1 浴室（bathrooms）

先看看浴室的数量分布

```
cnt_srs = train_df['bathrooms'].value_counts()
plt.figure(figsize=(10,5))
sns.barplot(cnt_srs.index,cnt_srs.values,alpha=0.8,color=color[2])
plt.xlabel("number of occurrences",fontsize = 12)
plt.ylabel("bathrooms",fontsize=12)
plt.show()
```

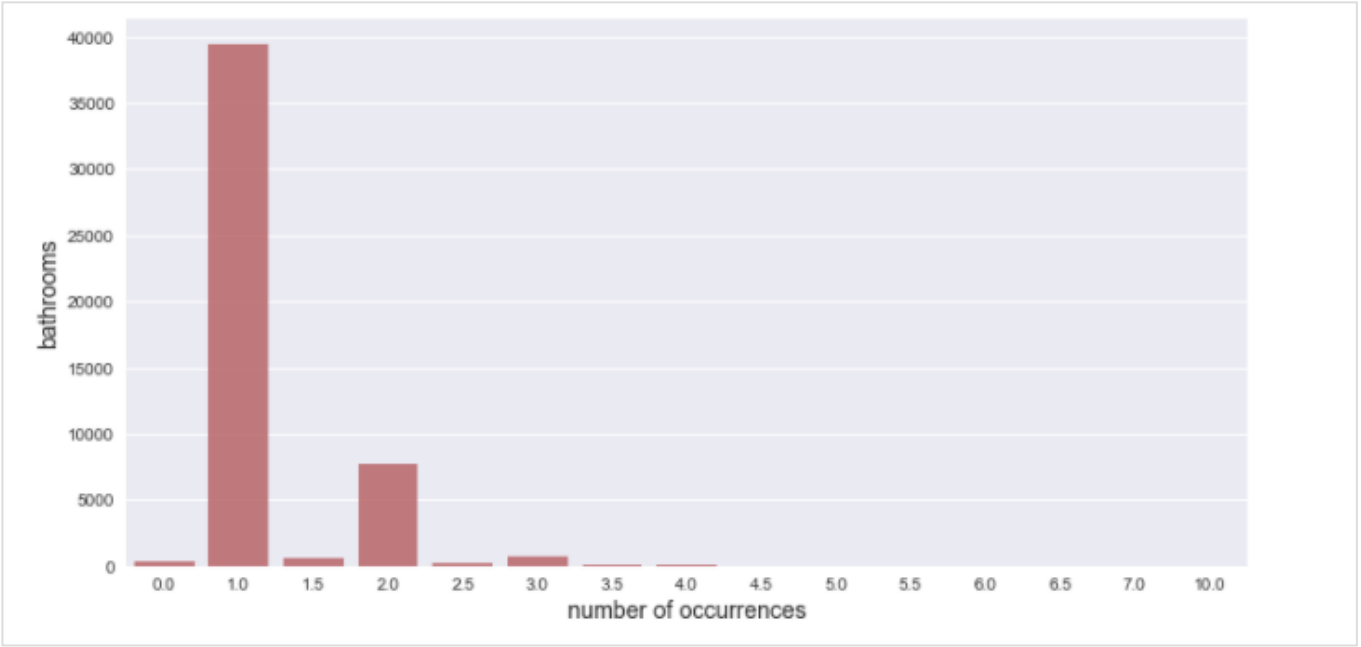

可以看到绝大多数的样例的浴室数量为1，其次为2个浴室。

再看看不同兴趣程度的浴室数量分布，运用小提琴图来呈现：

```
#浴室数量大于3的记为3
train_df['bathrooms'].loc[train_df['bathrooms']>3]=3

plt.figure(figsize=(12,6))
sns.violinplot(x = 'interest_level',y = 'bathrooms',data= train_df,alpha=0.8)
plt.xlabel("interest level",fontsize = 12)
plt.ylabel("bathrooms",fontsize=12)
plt.show()
```

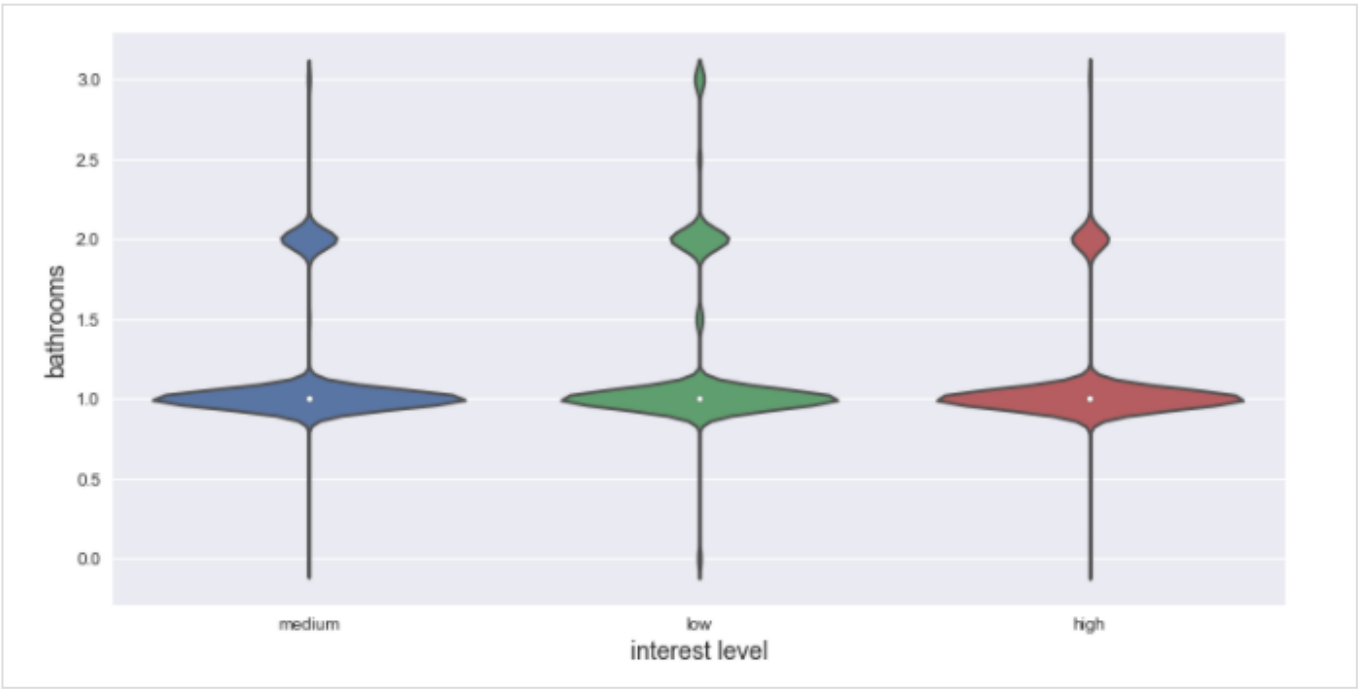

可以看到在不同的兴趣程度上，浴室数量的分布差不多。

2.3.2 卧室（bedrooms）

```
cnt_bedrooms = train_df['bedrooms'].value_counts()
plt.figure(figsize=(10,5))
sns.barplot(cnt_bedrooms.index,cnt_bedrooms.values,alpha=0.8,color=color[3])
plt.ylabel("number of occurrences",fontsize = 12)
plt.xlabel("bedrooms",fontsize=12)
plt.show()
```

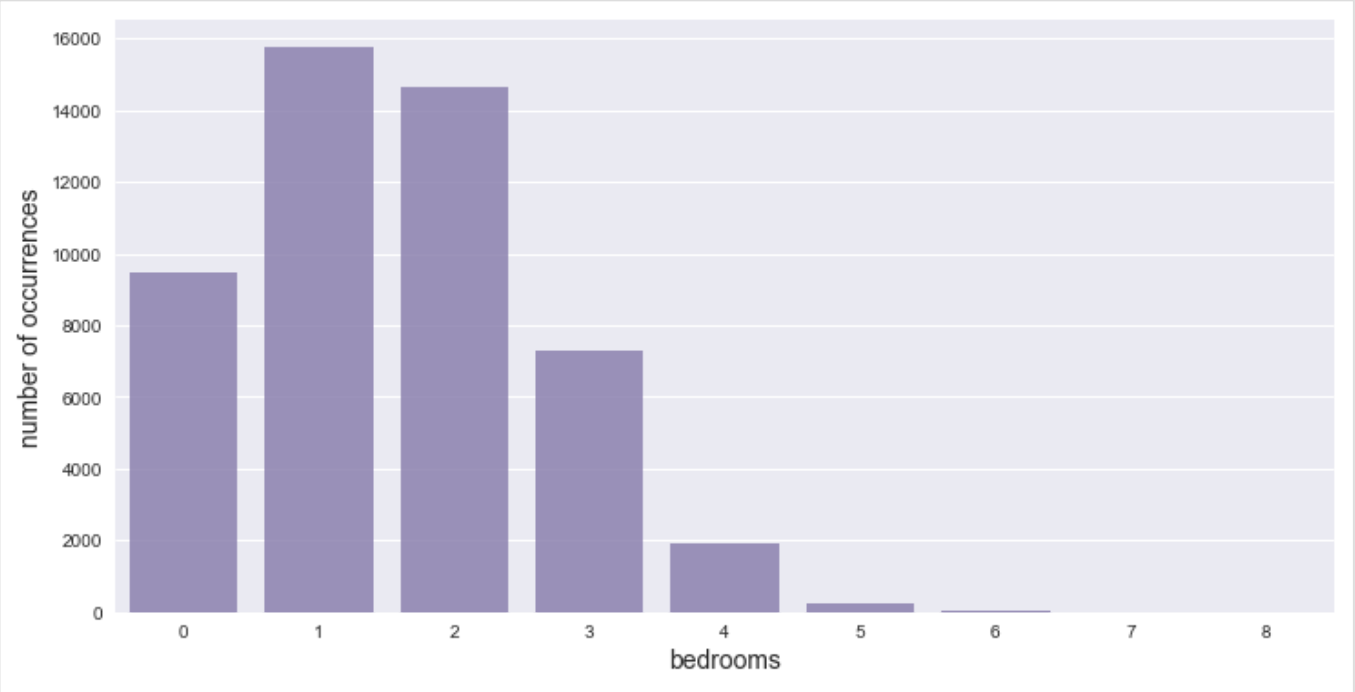

卧室数量基本集中在1和2，也有不少没有卧室，3个卧室的房子也不少。

看看不同兴趣程度的卧室数量分布，同样也用小提琴图来呈现：

```
plt.figure(figsize=(12,6))
sns.countplot(x='bedrooms',hue='interest_level',data=train_df)
plt.ylabel("number of occurrences",fontsize = 12)
plt.xlabel("bedrooms",fontsize=12)
plt.show()
```

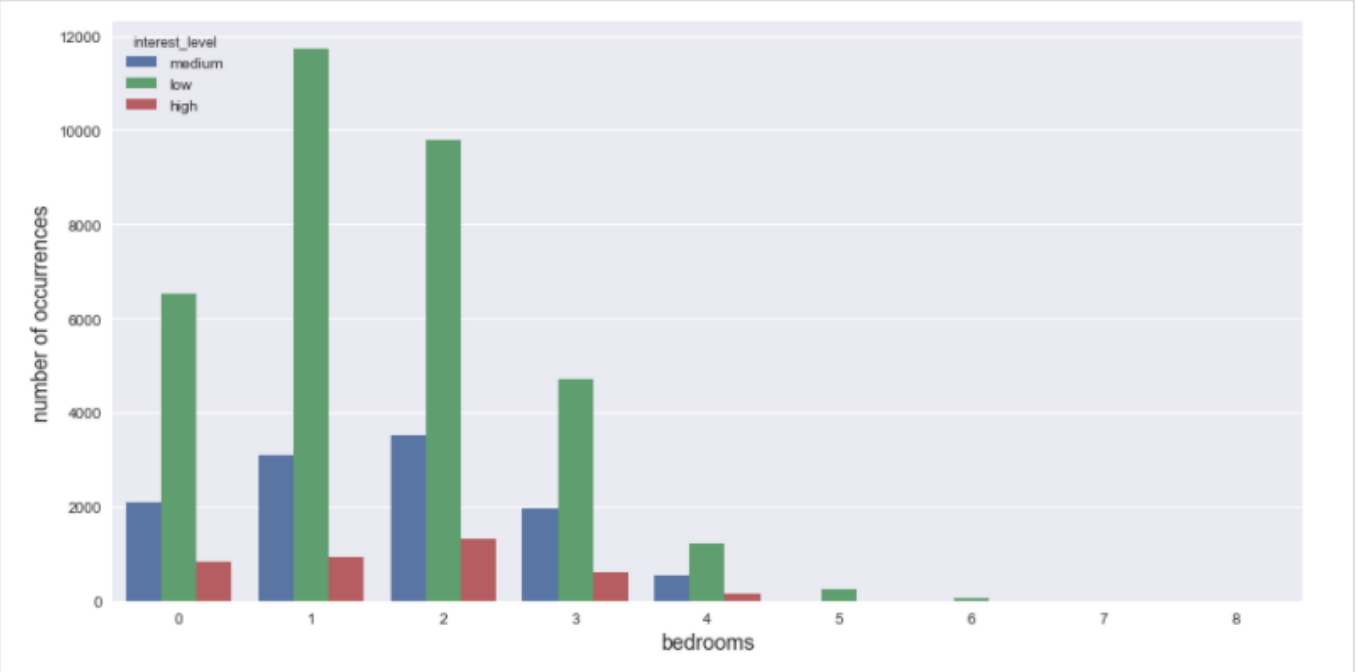

2.3.3 价格（price）

对价格排序，看一下价格的分布：

```
1  plt.figure(figsize=(10,5))
2  plt.scatter(range(train_df.shape[0]),np.sort(train_df.price.values))
3  plt.xlabel('index',fontsize=12)
4  plt.ylabel('price',fontsize=12)
5  plt.show()
```

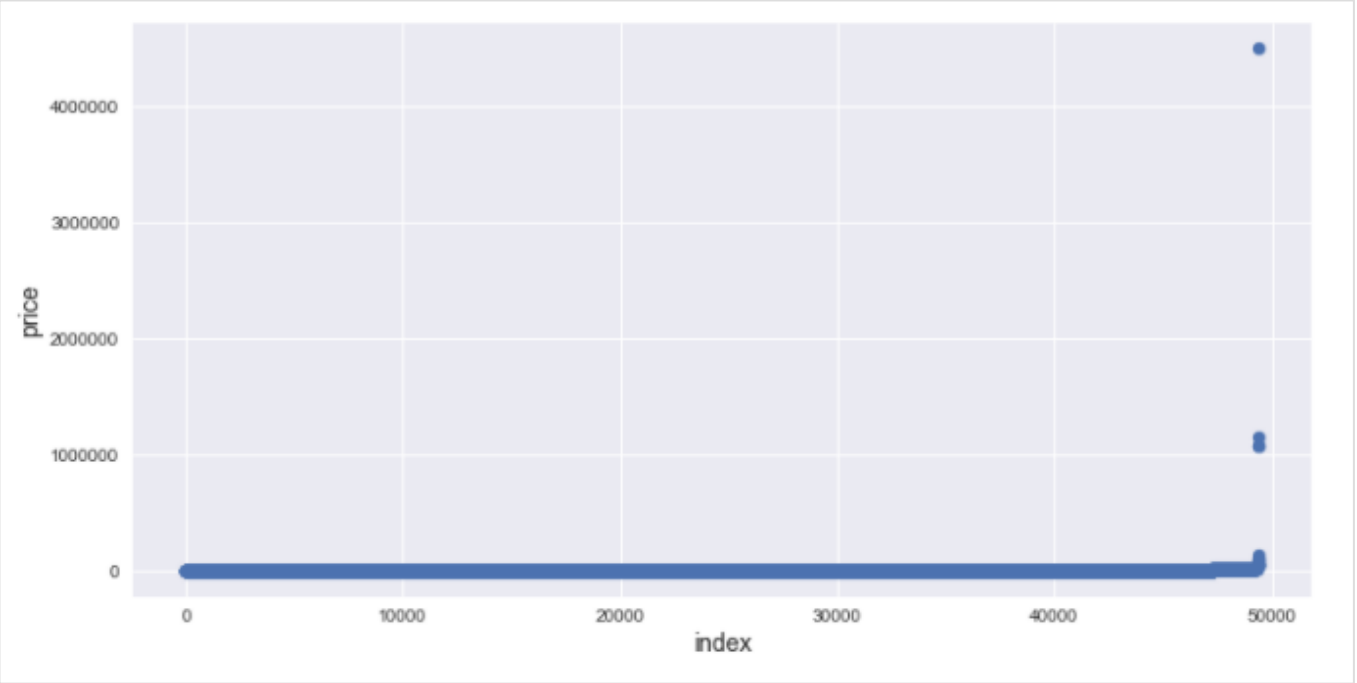

可以观察到有几个价格格外的高，视为异常值，我们把它们移除掉，然后再绘制分布直方图。

```
#99%分位数
ulimit = np.percentile(train_df.price.values,99)
train_df['price'].loc[train_df['price']>ulimit]=ulimit
plt.figure(figsize=(10,5))
sns.distplot(train_df.price.values,bins=50,kde=True,color=color[3])
plt.xlabel('price',fontsize=12)
plt.show()
```

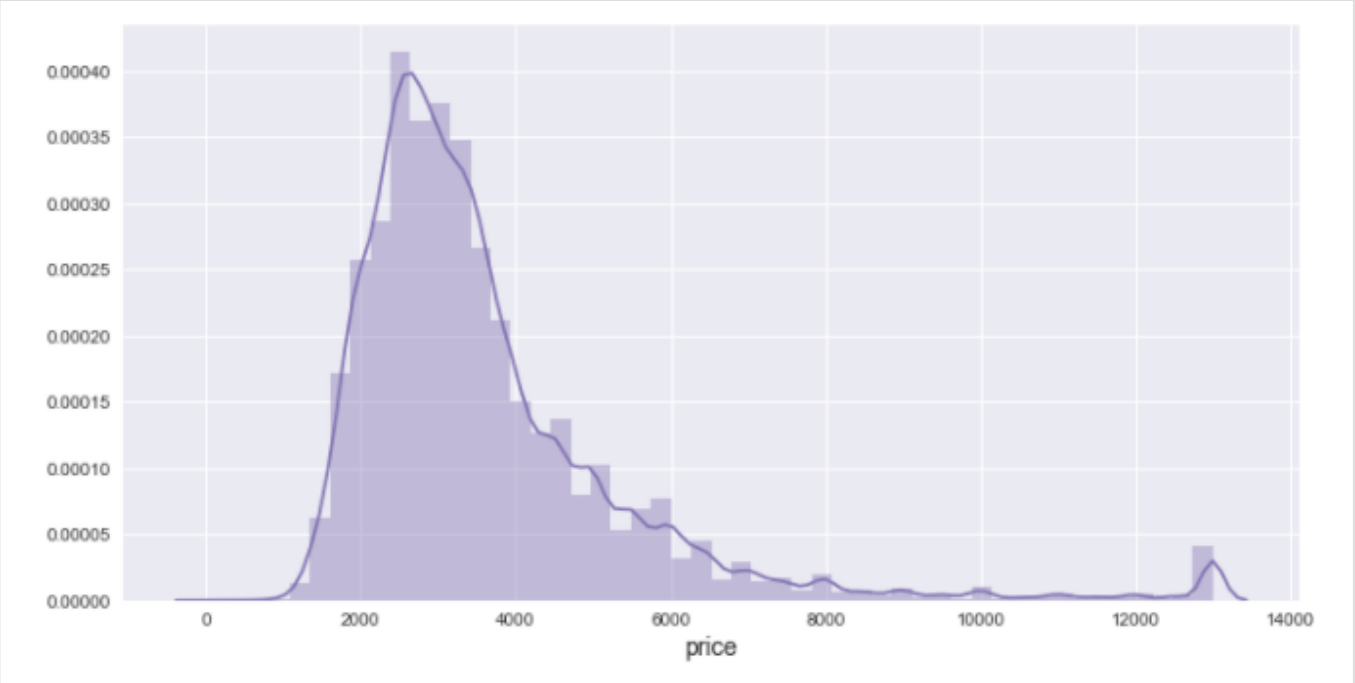

可以观察到分布略微有点右偏。

2.4 地理位置型

2.4.1 纬度（latitude）

先看看纬度的分布情况

```
#避免极端情况
llimit = np.percentile(train_df.latitude.values,1)
ulimit = np.percentile(train_df.latitude.values,99)

train_df['latitude'].loc[train_df['latitude']<llimit]=llimit
train_df['latitude'].loc[train_df['latitude']>ulimit]=ulimit

plt.figure(figsize=(10,5))
sns.distplot(train_df.latitude.values,bins=50,kde=True,color=color[3])
plt.xlabel('latitude',fontsize=12)
plt.show()
```

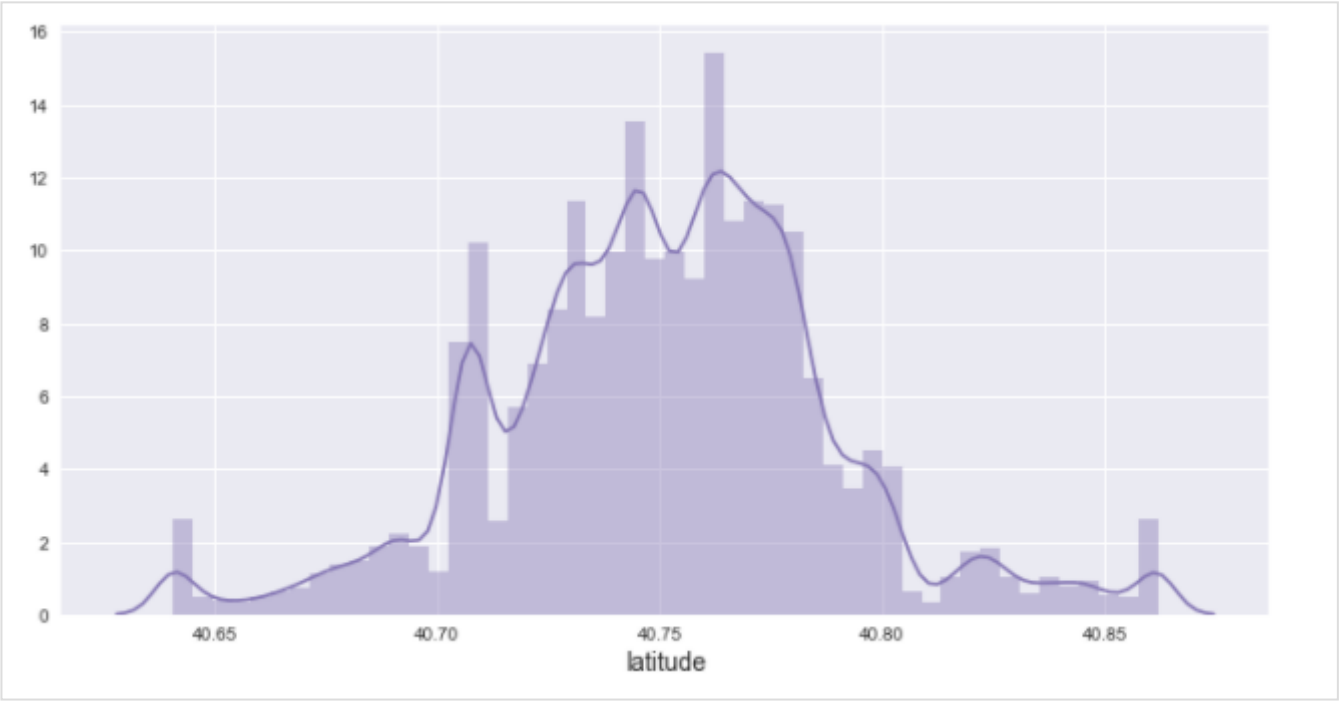

由图可知，纬度基本上介于40.6到40.9之间

2.4.2 经度（longitude）

```
#避免极端情况
llimit = np.percentile(train_df.longitude.values,1)
ulimit = np.percentile(train_df.longitude.values,99)

train_df['longitude'].loc[train_df['longitude']<llimit]=llimit
train_df['longitude'].loc[train_df['longitude']>ulimit]=ulimit

plt.figure(figsize=(12,6))
sns.distplot(train_df.longitude.values,bins=50)
plt.xlabel('longitude',fontsize=14)
plt.show()
```

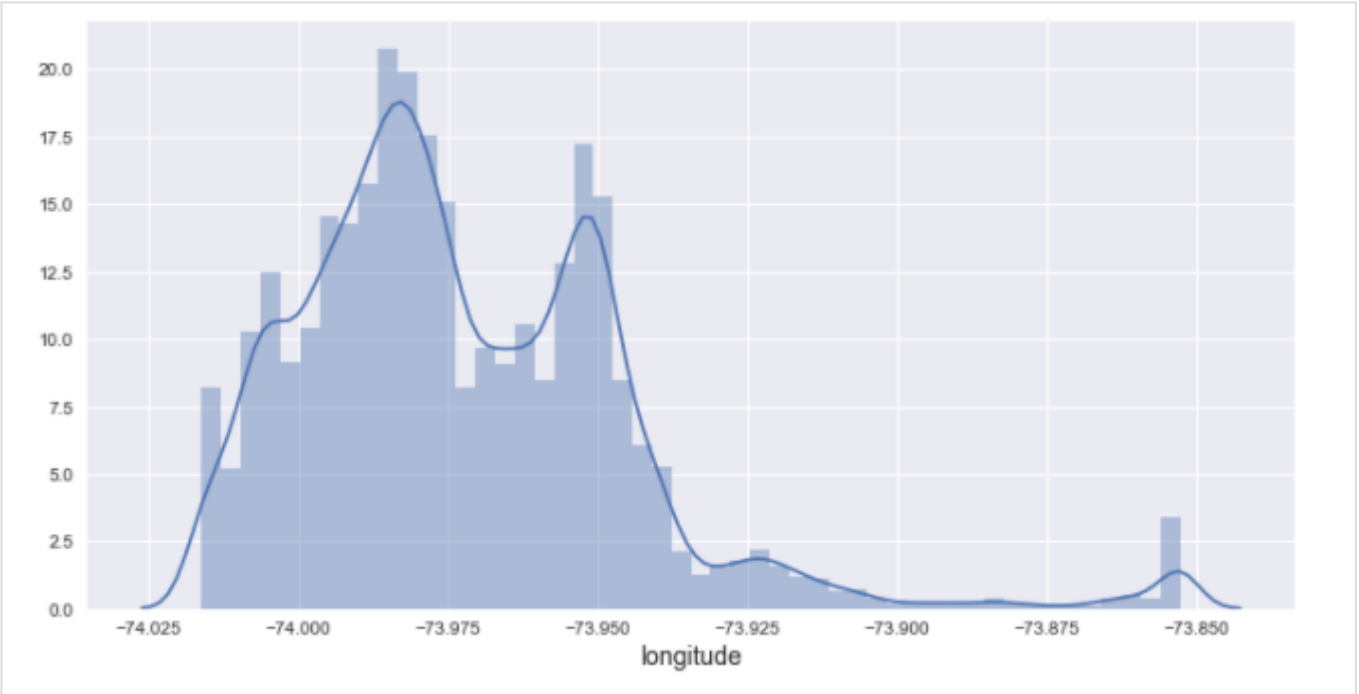

经度介于-73.8和-74.02之间。

接下来，我们尝试把经纬度对应到地图上，绘制成热图，也就是房源在地理位置上的分布密度图。

```
from mpl_toolkits.basemap import Basemap
from matplotlib import cm
west,south,east,north =-74.02,40.64,-73.85,40.86
fig =plt.figure(figsize=(16,12))
ax = fig.add_subplot(111)
m=Basemap(projection='merc',
          llcrnrlat=south,urcrnrlat=north,
          llcrnrlon=west,urcrnrlon=east,
          lat_ts=south,resolution='i')
x,y=m(train_df['longitude'].values,train_df['latitude'].values)
m.hexbin(x,y,gridsize=200,bins='log',cmap=cm.YlOrRd_r)
```

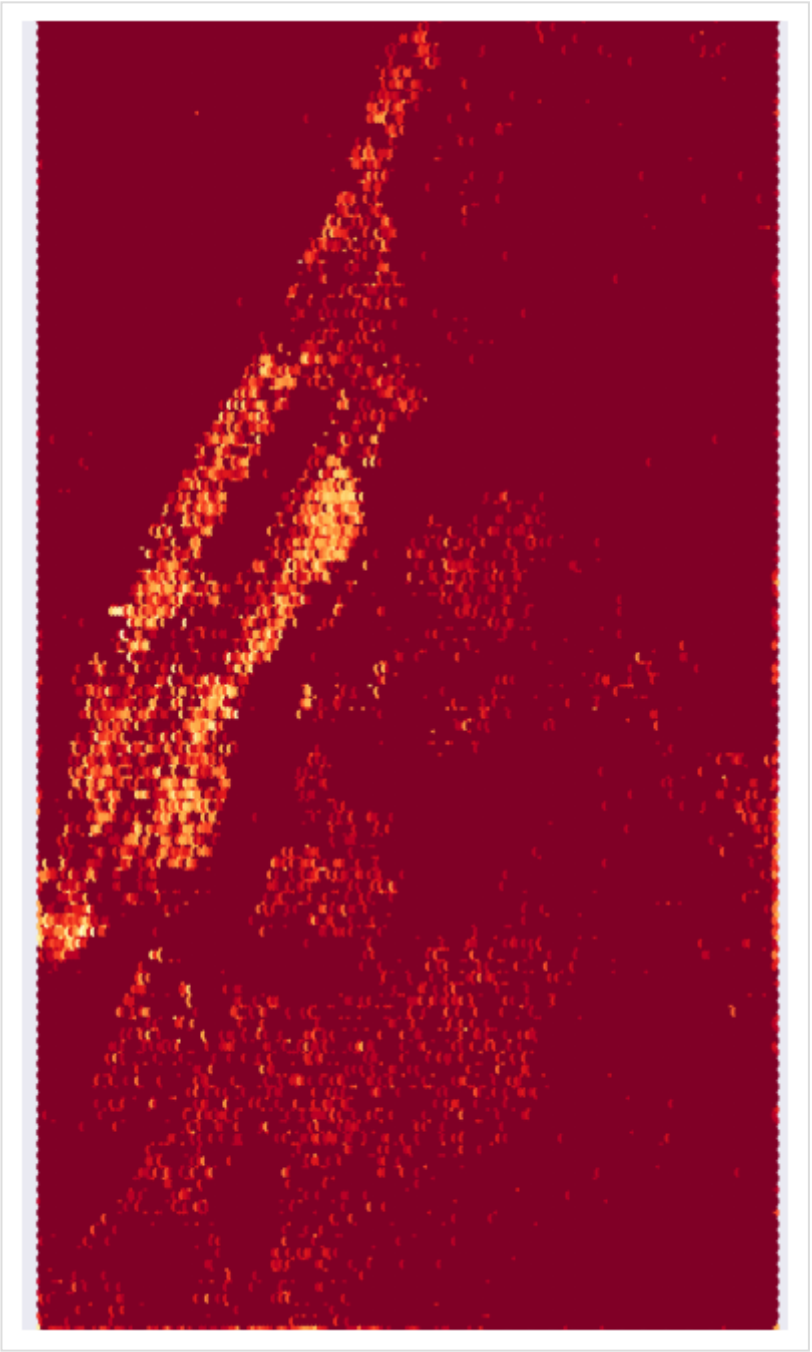

基本和纽约市的城市热图相匹配。

2.5 时间型

2.5.1 发布时间（Created）

先看一下不同时间的分布状况。

```
train_df['created']=pd.to_datetime(train_df['created'])
train_df['date_created']=train_df['created'].dt.date
cnt_srs = train_df['date_created'].value_counts()

plt.figure(figsize=(14,7))
```

```
ax = plt.subplot(111)
ax.bar(cnt_srs.index,cnt_srs.values,alpha=0.8)
ax.xaxis_date()
plt.xticks(rotation='vertical')
plt.show()
```

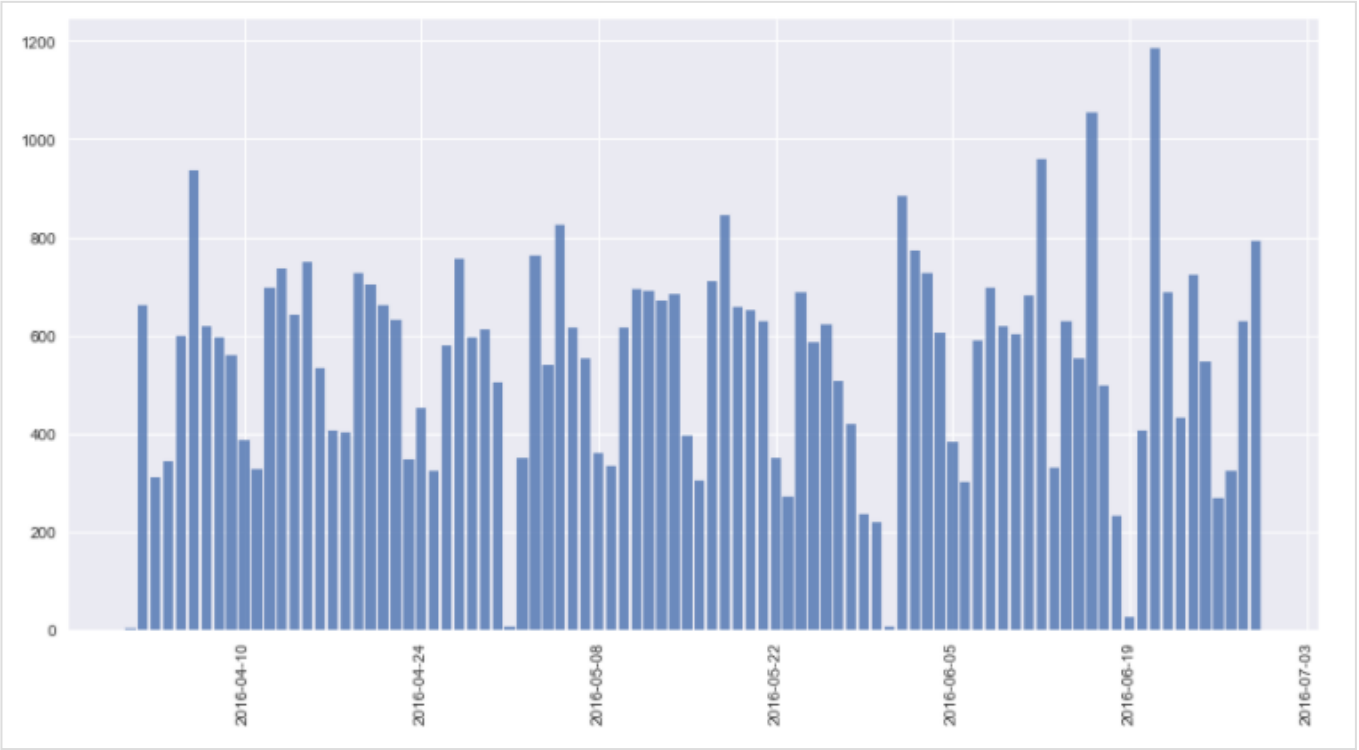

从图中观察到发布时间是从2016年的4月至6月，当然这是训练集的情况，对应的，再看看测试集的发布时间状况。

```
test_df['created']=pd.to_datetime(test_df['created'])
test_df['date_created']=test_df['created'].dt.date
cnt_srs = test_df['date_created'].value_counts()

plt.figure(figsize=(12,6))
ax = plt.subplot(111)
ax.bar(cnt_srs.index,cnt_srs.values,alpha=0.8)
ax.xaxis_date()
plt.xticks(rotation='vertical')
plt.show()
```

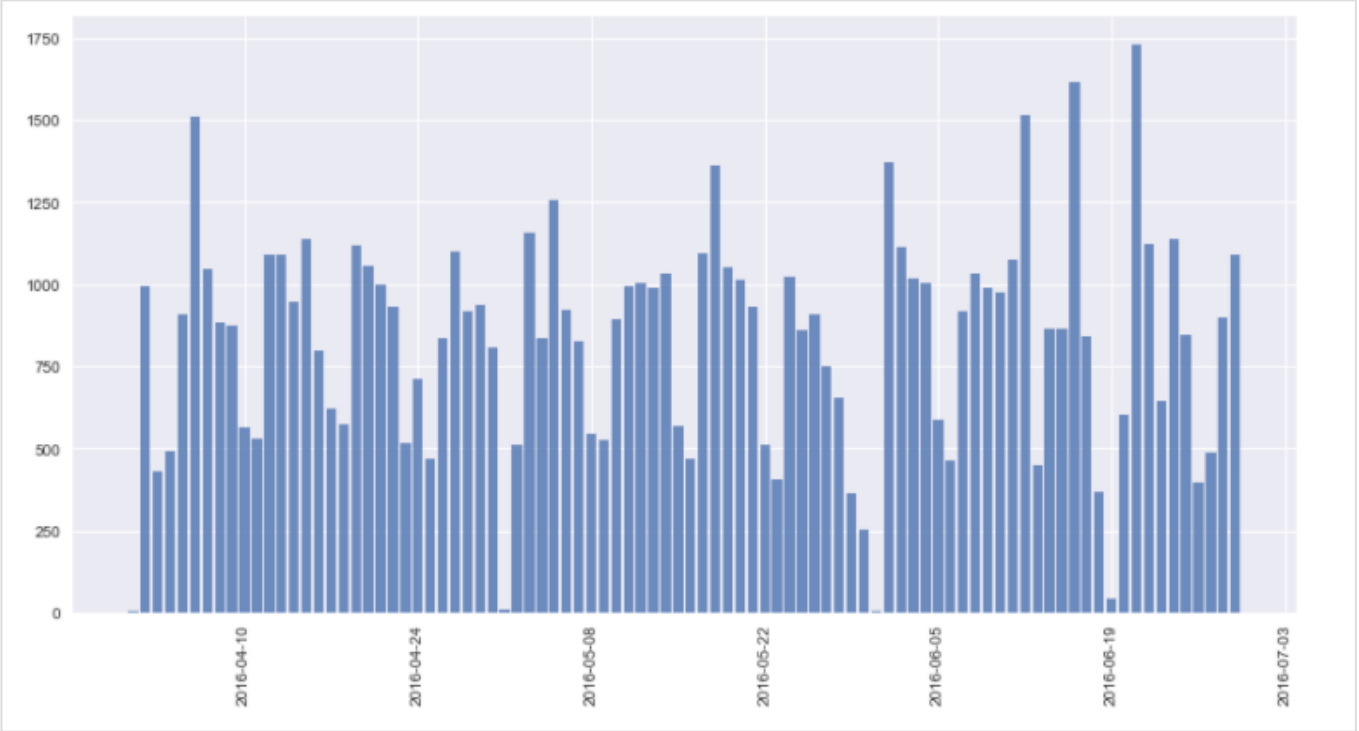

可知，测试集的时间分布和训练集类似。

再看看不同时刻的样本分布情况：

```
train_df['hour_created'] = train_df['created'].dt.hour
cnt_srs = train_df['hour_created'].value_counts()

plt.figure(figsize=(14,7))
sns.barplot(cnt_srs.index,cnt_srs.values,alpha=0.8,color=color[4])
plt.xticks(rotation='vertical')
plt.show()
```

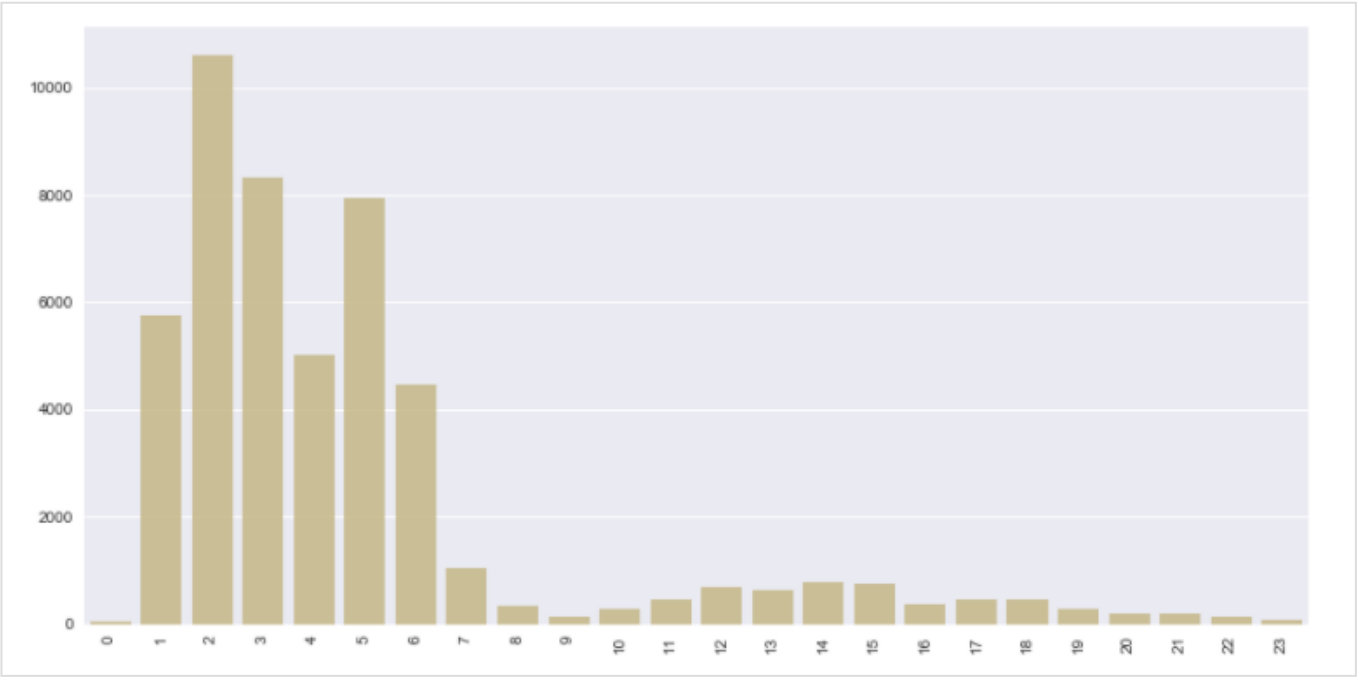

看起来像是一天中比较早的几个小时创建的比较多。可能是那个时候流量不拥挤，数据就更新了。

2.6 其他类型特征

2.6.1 展示地址（Display Address）

```
cnt_srs = train_df.groupby('display_address')['display_address'].count()
for i in [2,10,50,100,500]:
    print "Display_address that appear less than {} \
    times:{}%".format(i,round((cnt_srs<i).mean()*100,2))
```

上述代码中（cnt_srs<i）返回的是布尔值True | False。再求一个

得到的结果为：

Display_address that appear less than 2 times:63.22%

Display_address that appear less than 10 times:89.6%

Display_address that appear less than 50 times:97.73%

Display_address that appear less than 100 times:99.26%

Display_address that appear less than 500 times:100.0%

绘制展示地址频次分布直方图：

```
plt.figure(figsize=(12,6))
plt.hist(cnt_srs.values,bins=150,log=True,alpha=0.9)
plt.xlabel('Number of times display_adress appeared',fontsize=12)
plt.ylabel('log(Count)',fontsize=12)
plt.show()
```

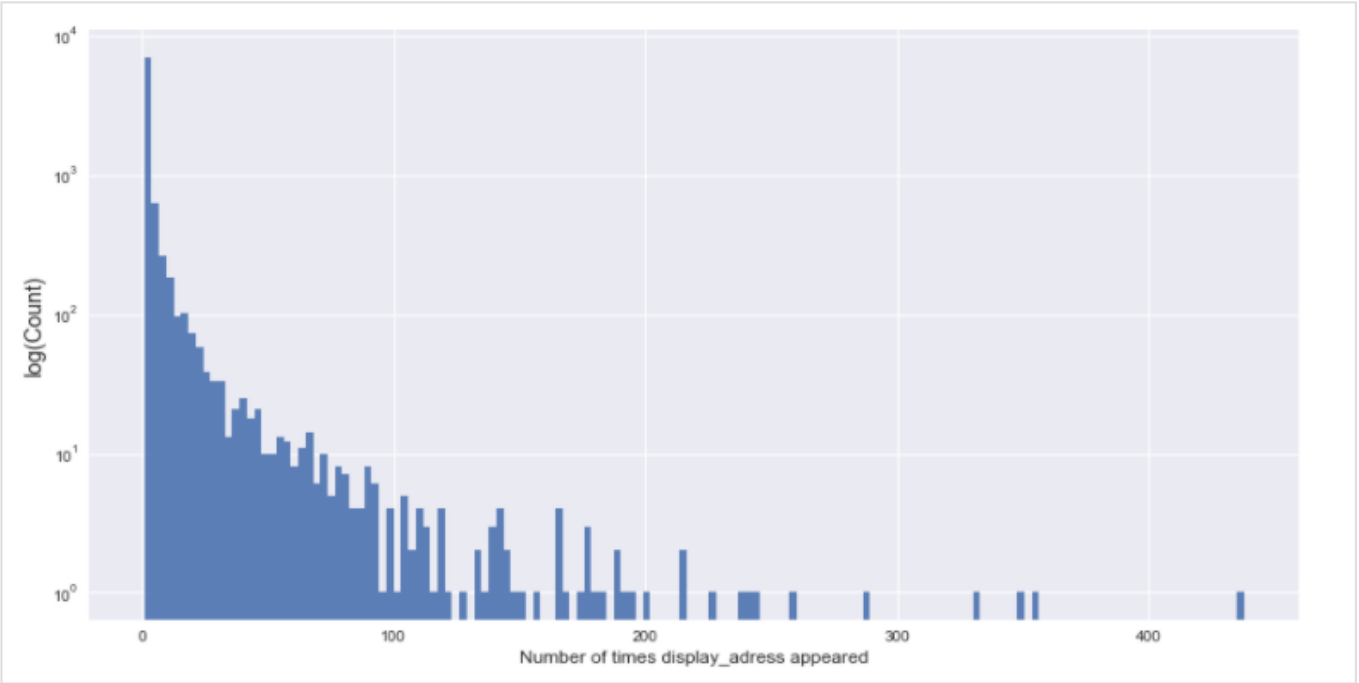

大部分的展览地址出现次数在给定的数据集中少于100次。没有超过500次的。

再看看展示地址的词云图：

```
# wordcloud for display address
plt.figure(figsize=(12,6))
wordcloud = WordCloud(background_color='white', width=600, height=300, max_font_size=50,
wordcloud.recolor(random_state=0)
plt.imshow(wordcloud)
plt.title("Wordcloud for Display Address", fontsize=30)
plt.axis("off")
plt.show()
```

2.6.2 照片数量（Photos）

这个比赛也有巨大的照片数据。让我们先看看照片的数量:

```
train_df["num_photos"] = train_df["photos"].apply(len)
cnt_srs = train_df['num_photos'].value_counts()

plt.figure(figsize=(14,7))
sns.barplot(x=cnt_srs.index,y=cnt_srs.values,alpha=0.8)
plt.xlabel("number of photos",fontsize=14)
plt.ylabel('number of occurrences',fontsize=14)
plt.show()
```

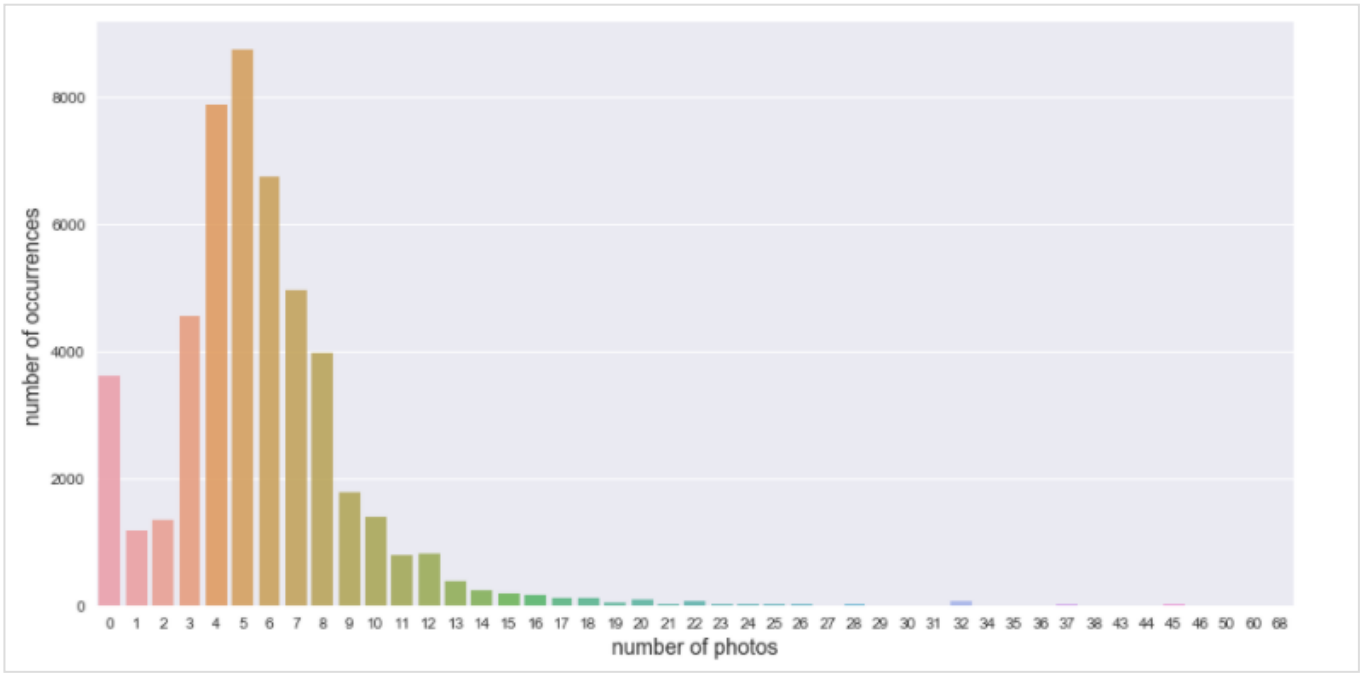

大多数样例的照片数量集中在3~8张。

再来看看不同兴趣程度下的照片数量分布：

```
train_df['num_photos'].loc[train_df['num_photos']>12]=12
plt.figure(figsize=(14,7))

sns.violinplot(x='num_photos',y='interest_level',data=train_df,order=['low','medium','hi
plt.xlabel('Number of photos',fontsize=12)
plt.ylabel("Interest Level",fontsize=12)
plt.show()
```

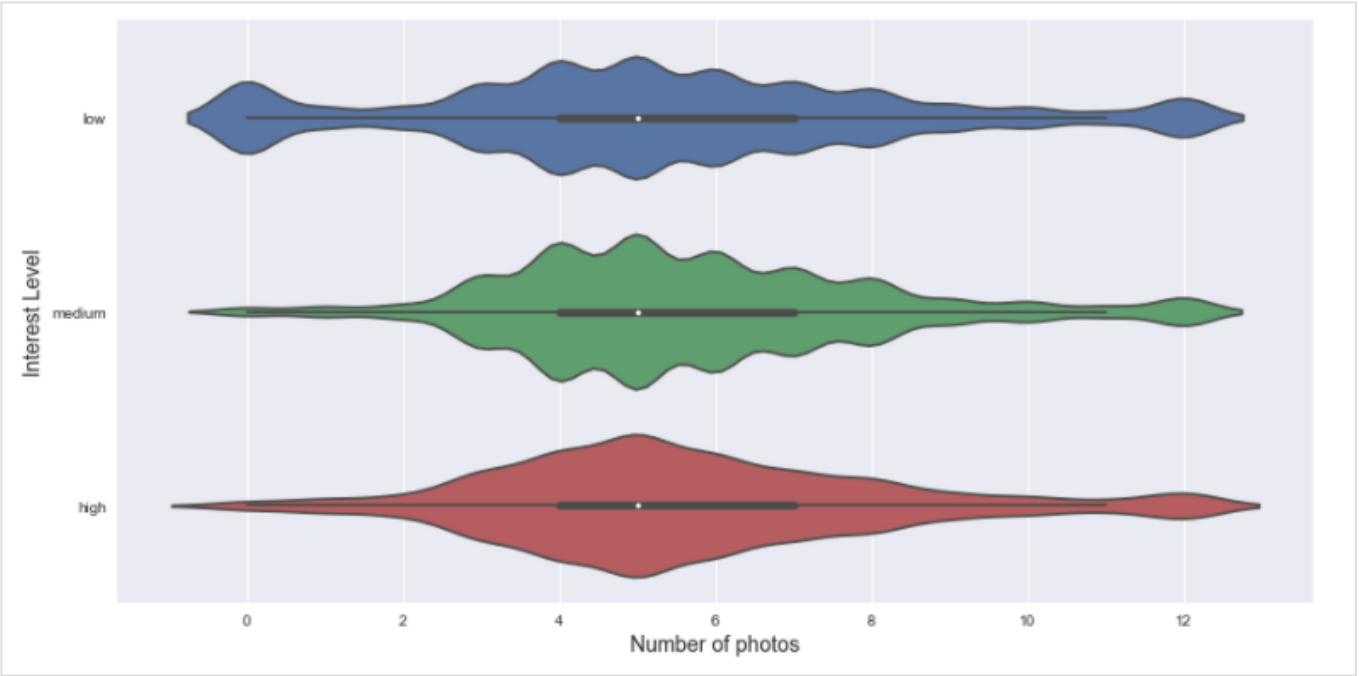

2.6.3 描述特征的数量（features）

每一个房源都对应一个features列，它描述了该样例的特征，比如位于市中心呀、能养猫呀、可以肆意遛狗，类似于这种亲民的特点。有的时候，这种利民条件越多，或许会提高消费者的兴趣，当然也不一定，可以先来看看特征数量的分布：

```
train_df['num_features'] = train_df['features'].apply(len)
cnt_srs = train_df['num_features'].value_counts()

plt.figure(figsize=(14,7))
sns.barplot(x=cnt_srs.index,y=cnt_srs.values,alpha=0.8)
plt.ylabel('Number of Occurrences',fontsize=12)
plt.xlabel('Number of features',fontsize=12)
plt.show()
```

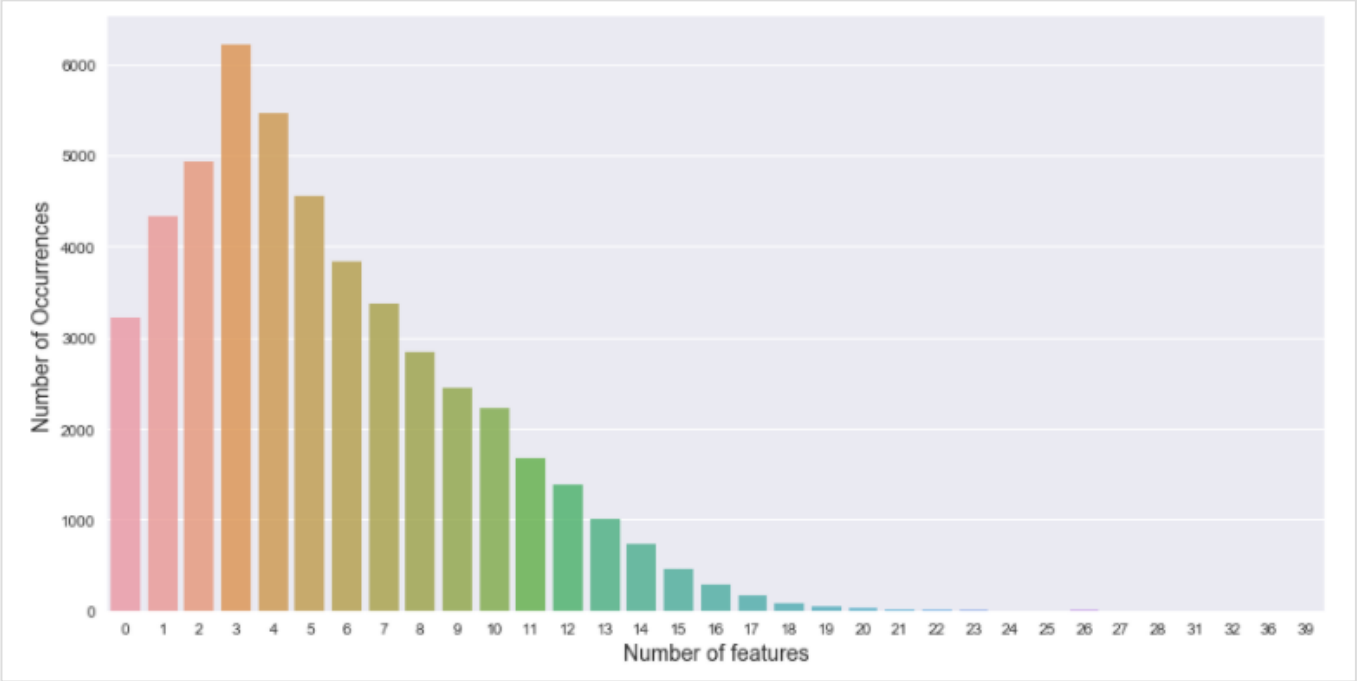

再看看不同兴趣程度下的描述特征数量分布：

```
#避免极端情况
train_df['num_features'].loc[train_df['num_features']>17]=17

plt.figure(figsize=(14,7))
sns.violinplot(y='num_features',x='interest_level',\
               data=train_df,order=['low','medium','high'])
plt.xlabel('Interest Level',fontsize=12)
plt.ylabel('Number of features',fontsize=12)
plt.show()
```

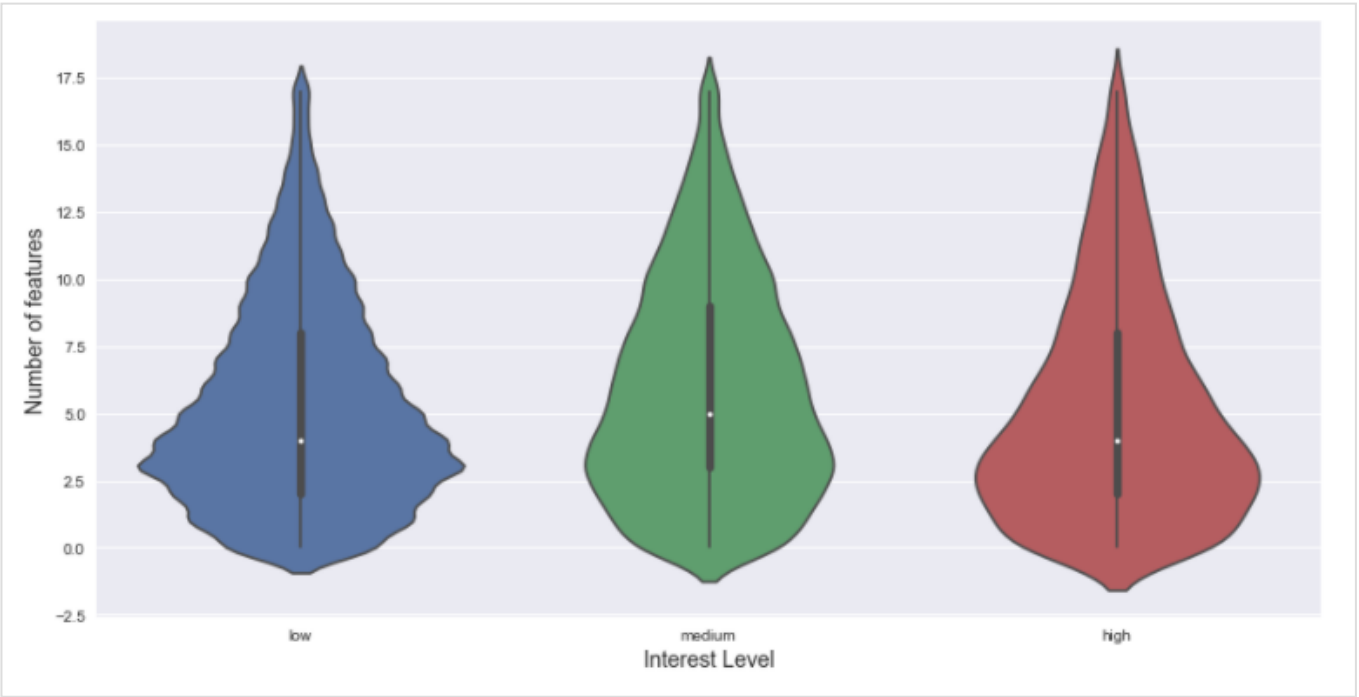

也可以看看描述特征的词云：

```
from wordcloud import WordCloud
text = ''
text_da = ''
for index,row in train_df.iterrows():
    for feature in row['features']:
        text = ' '.join([text,"_".join(feature.strip().split(" "))])
        text_da = " ".join([text_da,"_".join(row['display_address'].strip().split(" "))
text = text.strip()
text_da = text_da.strip()
plt.figure(figsize=(14,7))
wordcloud = WordCloud(background_color='white',width=600,                    height=30
wordcloud.recolor(random_state=0)
plt.imshow(wordcloud)
plt.title("Wordcloud for features",fontsize=30)
plt.axis("off")
plt.show()
```

以上这些探索性分析只是对原始数据初步的认识与了解，完了就可以建立一个base model。随着之后的特征工程对其进行更深层次的探索挖掘，不断迭代，使得我们的模型的预测效果越来越好。下一篇就开始着手建立一些base model。

kaggle # EDA # 可视化 # 特征工程

数据分析系列（3）：数据倾斜

kaggle系列（3）：Rental Listing Inquiries（二）：XGBoost